

멀티모달 의료 데이터를 활용한 난소암 계층적 진단·재발 예후 예측 및 LLM 기반 임상 보고서 생성 AI 모델 개발

졸업 프로젝트 그로스 연구트랙 2차 보고서

13 최우수팀 김문경, 박선영, 안서연

지도교수 : 황의원

[초록]

본 연구는 CT 영상과 환자의 임상 데이터를 통합한 멀티모달 딥러닝 모델을 구축하여 난소암의 악성도 진단과 재발 위험 예측을 동시에 수행하며, LLM 기반 RAG 시스템을 통해 근거 기반 임상 보고서를 자동 생성하는 AI 시스템을 개발하는 것을 목표로 한다. 난소 종양은 악성 여부와 재발 여부에 따라 치료 전략과 예후가 크게 달라지기 때문에 정확한 진단과 예후 예측이 중요하며, 이를 위해 의료 영상 정보와 임상 정보를 통합적으로 분석하는 AI 시스템의 필요성이 증대되고 있다.

본 단계에서는 전 단계에서 구축한 악성·양성 진단 모델을 기반으로, 재발 예측 기능을 통합한 멀티태스크 · 멀티모달 모델로 확장하였다. 재발 라벨이 존재하는 환자(Labeled)가 소수이고 악성 여부 라벨만 존재하는 환자(Unlabeled)가 다수인 준지도학습 환경에서, Mean Teacher 프레임워크를 도입하여 Unlabeled 데이터를 학습에 활용하였다. ResNet50-Fusion, ViT-Fusion, Hybrid-Fusion 세 가지 백본에 대한 5-Fold Cross-Validation 비교 실험을 수행한 결과, 재발 예측과 악성 예측 모두에서 균형 있는 성능을 보인 ResNet50-Fusion 모델이 재발 예측 ROC-AUC 0.915, Sensitivity 0.850, 악성 예측 ROC-AUC 0.930, Sensitivity 0.858을 달성하였다. 설명 가능성 측면에서는 Grad-CAM 기반 시각적 근거 제시 기능과 YOLO 기반 병변 탐지 기능을 구현하였으며, LLM(Qwen 3.5-0.8B)과 FAISS 기반 벡터 DB를 활용한 RAG 시스템을 통해 난소암 관련 가이드라인 및 논문에 근거한 임상 보고서 자동 생성 파이프라인을 설계하였다. 이러한 결과는 CT 영상 기반 멀티모달 AI 시스템이 난소암의 악성도 진단과 재발 예측을 통합적으로 지원할 수 있음을 시사하며, 최종 목표인 근거 기반 임상 의사결정 지원 시스템 구축을 위한 핵심 기술을 성공적으로 확립하였다.

핵심 주제어: 난소암, 난소암 진단, 재발 예측, 멀티모달, 의료 AI, XAI

목차

I.	팀 정보	4
	A. 과제명	
	B. 팀 정보	
	C. 팀 구성원	
II.	과제 요약	5
	A. 문제 정의	
	B. 기존 연구와의 비교	
	C. 제안 내용	
	D. 기대 효과 및 의의	
	E. 주요 기능 리스트	
III.	과제 설계	14
	A. 요구사항 정의	
	B. 전체 시스템 구성	
	C. 주요 엔진 및 기능 설계	
	D. 주요 기능의 구현	
IV.	참고 문헌	37

그림 · 표 목차

[그림 1] 타 연구의 LLM 기반 임상 보고서 생성 프레임워크

[그림 2] 타 연구의 LLaVA-Ra 모델 개요

[그림 3] 난소암 진단 및 치료 분야 대규모 언어 모델(LLM) 벤치마킹에 대한 타 연구

[그림 4] 전체 시스템 구성도

[그림 5] Grad-CAM 히트맵 시각화 결과

[표 1] 멀티모달 융합 모델 실험 결과

[표 2] 재발 여부 라벨 분포

I. 팀 정보

A. 과제명

- 멀티모달 의료 데이터를 활용한 난소암 계층적 진단·재발 예후 예측 및 LLM 기반 임상 보고서 생성 AI 모델 개발
- Development of an AI Model for Hierarchical Diagnosis and Recurrence Prognosis Prediction of Ovarian Cancer Using Multimodal Medical Data with LLM-Based Clinical Report Generation

B. 팀 정보

- 팀 번호: 13
- 팀명: 최우수

C. 팀 구성원

1. 김문경 : Image encoder 개발 및 Multimodal fusion
 - a. CT 영상을 입력으로 하는 Image encoder 모듈 개발을 담당
 - b. ResNet50, ViT(Vision Transformer), Hybrid 모델의 성능을 비교 분석
 - c. Downstream task에 활용 가능한 latent feature embedding 생성을 구현
 - d. 악성 여부 단일 태스크 멀티모달 모델 구현
 - e. YOLO 기반 종양 위치 탐지 모델 구현
2. 박선영 : 임상 데이터 전처리 및 Text encoder·RAG-LLM 구현
 - a. Table 형식의 임상 데이터를 입력으로하는 Text encoder 모듈 개발을 담당
 - b. 임상 데이터의 결측치 처리 및 feature selection
 - c. 임상 지표를 반영할 수 있는 구조 embedding을 생성하여 downstream fusion에 활용될 수 있도록 설계
 - d. RAG-LLM 기반 임상 보고서 생성 모델 구현
3. 안서연 : 이미지 데이터 전처리 및 Multimodal fusion
 - a. 난소암 데이터셋의 수집·정제·라벨 정렬 및 전체 데이터 전처리 파이프라인 구축을 총괄
 - b. Image encoder와 Text encoder에서 추출된 feature를 결합하는 Multimodal fusion 모듈 개발을 담당
 - c. ~~Concatenation, Cross-attention, Contrastive learning 등 다양한 융합 전략을 비교하고 실험을 설계~~
 - d. 계층적 진단 구조에 맞춰 데이터 라벨 구조 및 실험 설계를 조정
 - e. 재발 예측 및 악성도 예측을 위한 Mean Teacher Semi-Supervised Learning 기반 멀티모달 모델 구현

II. 과제 요약 (Project Summary)

A. 문제 정의

난소암(Ovarian cancer)은 여성 생식기 악성 종양 중 가장 높은 사망률을 보이는 암종으로, 진단 시기가 늦어질수록 예후가 급격히 악화되는 것으로 보고되어 있다¹. 초기에는 증상이 비특이적이거나 거의 나타나지 않아 ‘침묵의 살인자’로 불리며, 다수의 환자가 진행된 병기에서 진단되는 것이 현실이다. 난소 종양은 benign – borderline – malignant로 이어지는 계층적 특성을 가지며, 조직학적 아형과 악성 위험도에 따라 치료 전략이 크게 달라진다. 특히 수술 여부, 상급 의료기관 의뢰 기준, 가임력 보존 여부 등 핵심 임상 의사결정은 종양의 악성 가능성 평가에 직접적으로 의존한다.

더 나아가 난소암은 치료 후에도 약 70% 내외의 높은 재발률을 보이는 것으로 보고되어 있으며², 이로 인해 단순한 양성·악성 이진 분류를 넘어 초기 진단 단계에서부터 재발 위험을 정량적으로 예측할 수 있는 모델의 필요성이 지속적으로 제기되고 있다. 이러한 임상적 특성으로 인해, 난소 종양의 악성 위험도를 정확하고 일관되게 평가할 수 있는 정밀 진단 기술의 중요성을 더욱 부각시킨다.

현재 임상에서는 transvaginal ultrasound, CT와 같은 영상 기법과 함께 환자의 연령, 혈액 바이오마커(CA-125, HE4), 폐경 여부 등 다양한 임상 정보를 종합하여 악성 가능성을 판단한다. 이 중 초음파 검사는 접근성과 비용 효율성 측면에서 1차 진단 도구로 널리 활용되며, 숙련된 검사자가 시행할 경우 높은 진단 정확도를 보인다. 그러나 초음파 영상은 검사자 의존성이 크고, 판독 경험에 따라 정확도가 크게 달라질 수 있으며, 비숙련 인력의 경우 진단 일관성이 유지되지 않는다는 한계가 반복적으로 보고되어 왔다³. CT 또한 종양의 고형·낭성 구성, subtype, 복막 파종 여부 등 복합적인 요소를 해석해야 하므로 영상 판독자의 경험에 따라 결과가 달라질 수 있다. 더불어 난소 종양은 조직 생검이 종양 파종 위험으로 인해 제한되는 경우가 많아, 영상 기반의 악성 위험 예측 체계는 임상적으로 필수적임에도 불구하고 여전히 높은 변동성과 주관성을 가지고 있다.

최근 이러한 한계를 극복하기 위한 방안으로 의료 인공지능(AI), 특히 멀티모달 딥러닝(multimodal deep learning)이 주목받고 있다. 의료 영상(초음파, CT, WSI)과 임상 지표, 병리 정보를 통합하여 하나의 모델이 end-to-end로 악성 위험도와 병리 아형을 예측하는 연구가 증가하고 있으며, 난소 종양 병변 탐지 AI가 실제 임상

¹ Bray, F., Ferlay, J., Soerjomataram, I., Siegel, R. L., Torre, L. A., & Jemal, A. (2018). *Global cancer statistics 2018: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries*. CA: A Cancer Journal for Clinicians, 68(6), 394 – 424. <https://doi.org/10.3322/caac.21492>

² du Bois, A., Reuss, A., Pujade-Lauraine, E., Harter, P., Ray-Coquard, L., & Pfisterer, J. (2009). *Role of surgical outcome as prognostic factor in advanced epithelial ovarian cancer: A combined exploratory analysis of three prospectively randomized phase 3 multicenter trials*. Cancer, 115(6), 1234 – 1244. <https://doi.org/10.1002/cncr.24149>

³ Timmerman D, Van Calster B, Testa A, Savelli L, Fischerova D, Froyman W, Wynants L, Van Holsbeke C, Epstein E, Franchi D, Kaijser J, Czekierdowski A, Guerriero S, Fruscio R, Leone FPG, Rossi A, Landolfo C, Vergote I, Bourne T, Valentin L. Predicting the risk of malignancy in adnexal masses based on the Simple Rules from the International Ovarian Tumor Analysis group. Am J Obstet Gynecol. 2016 Apr;214(4):424–437. doi: 10.1016/j.ajog.2016.01.007. Epub 2016 Jan 19. PMID: 26800772.


workflow에서 높은 성능과 일반화 가능성을 보였다는 국제 다기관 검증 연구도 보고되었다⁴. 이러한 결과는 단일 모달리티 접근을 넘어 다원적 정보 통합이 난소암 진단의 정확도와 신뢰성을 향상시킬 수 있음을 시사한다.

더 나아가 최근에는 의료 LLM(large language model)을 활용하여 AI 예측 결과를 구조화된 임상 보고서 형태로 자동 생성함으로써, 영상 및 임상 정보를 통합 해석하는 과정에서 발생하는 정보 손실과 판독 편차를 줄이려는 시도도 활발히 이루어지고 있다. 이는 AI 모델의 예측을 단순한 수치 출력에 그치지 않고, 실제 임상 의사결정에 활용 가능한 형태로 제공하려는 중요한 흐름이라 할 수 있다.

따라서 본 연구는 이러한 최신 이론적 기반과 선행연구를 바탕으로, CT 영상과 임상 정보를 통합한 멀티모달 딥러닝 프레임워크를 설계하여 난소암을 정밀하게 예측하고자 한다. CT 영상 인코더로는 제한된 의료 영상 데이터 환경에서도 안정적인 성능을 보이는 CNN 및 ViT(Vision Transformer)을 활용하여 종양의 경계, 텍스처, 내부 구조와 같은 형태학적 특징을 효과적으로 추출한다. 임상 데이터는 다층 퍼셉트론(MLP)을 통해 임베딩하여 영상 기반 특징을 보완하는 보조적 정보로 활용한다. 영상 데이터와 임상 데이터를 동시에 사용하여 예측 성능을 높이기 위한 Fusion 방법으로는 Concatenation, Cross-attention, Contrastive-learning 3가지 방식을 실험하여 더 성능이 높은 것을 채택한다. 최종적으로 RAG를 기반으로 하여 영문 및 한글 난소암 진단 가이드라인을 VectorDB에 구축함으로써 신뢰성 있는 LLM 임상 보고서를 생성하는 것을 목표로 한다.

B. 기존 연구와의 비교

1. AI 진단 + 예측 + 보고서 생성을 하나의 파이프라인으로 통합




[그림 1] 타 연구의 LLM 기반 임상 보고서 생성 프레임워크⁵

⁴ Christiansen, F., Konuk, E., Ganeshan, A. R., Welch, R., Palés Huix, J., Czekierdowski, A., Leone, F. P. G., Haak, L. A., Fruscio, R., Gaurilcikas, A., Franchi, D., Fischerova, D., Mor, E., Savelli, L., Pascual, M. À., Kudla, M. J., Guerriero, S., Buonomo, F., Liuba, K., Montik, N., Alcázar, J. L., Domali, E., Pangilinan, N. C. P., Carella, C., ... Epstein, E. (2025). *International multicenter validation of AI-driven ultrasound detection of ovarian cancer*. *Nature Medicine*, 31, 189–196. <https://doi.org/10.1038/s41591-024-03352-3>

⁵ Tanno, R., Barrett, D. G. T., Sellergren, A., Ghaisas, S., Dathathri, S., See, A., Welbl, J., Lau, C., Tu, T., Azizi, S., Singhal, K., Schaekermann, M., May, R., Lee, R., Man, S., Mahdavi, S., Ahmed, Z., Matias, Y., Barral, J., ... Ktena, I. (2025). *Collaboration between clinicians and vision – language models in radiology report generation*. *Nature Medicine*, 31, 599–608. <https://doi.org/10.1038/s41591-024-03302-1>

이 연구는 흉부 X-ray 영상만을 입력으로 하여 LLM 기반 임상 보고서를 생성하는 구조이지만, 우리 연구는 의료 영상과 임상 데이터를 입력으로 하여 난소 종양 진단 및 재발 예측 모델을 개발하고 이 모델의 예측 결과를 바탕으로 LLM 기반 임상 보고서를 생성하는 구조이다. 즉, 이 연구를 비롯한 기존 연구들은 보고서 생성을 중심으로 하였다면 우리 연구는 AI 진단 모델, 예후 예측, 보고서 생성이 하나의 통합된 파이프라인이라는 차별점이 있다.

2. 난소암에 특화된 모델



[그림 2] 타 연구의 LLaVA-Ra 모델 개요⁶

이 연구는 흉부 X-ray 이미지와 텍스트 쌍을 인코더로 학습시켜 인코더가 흉부 X-ray 이미지에서 자유 형식 텍스트 소견을 생성함으로써 임상에서의 접근성 및 비용, 성능 격차를 해소한 연구이다. 이 연구를 비롯한 기존의 많은 연구들은 대부분 흉부 X-ray나 뇌 MRI 기반 연구가 많다. 난소암에 대하여 영상과 임상 데이터를 통합한 멀티모달 진단, LLM 기반 임상 보고서 생성까지 포괄하는 연구는 아직 없다.

⁶Zambrano Chaves, J. M., Huang, S.-C., Xu, Y., Xu, H., Usuyama, N., Zhang, S., Wang, F., Xie, Y., Khademi, M., Yang, Z., Awadalla, H., Gong, J., Hu, H., Yang, J., Li, C., Gao, J., Gu, Y., Wong, C., Wei, M., ... Poon, H. (2025). A clinically accessible small multimodal radiology model and evaluation metric for chest X-ray findings. *Nature Communications*, 16, 3108. <https://doi.org/10.1038/s41467-025-58344-x>

3. 암 진단에 LLM 활용

Open Access Article

Decoding AI Competence: Benchmarking Large Language Models (LLMs) in Ovarian Cancer Diagnosis and Treatment—A Systematic Evaluation of Generative AI Accuracy and Completeness

by Haojie Cai[†] , Chao Wang[†] , Yue Zhang , Hui Ding , Wei Hong , Yaqian Zhao , Shanshan Cheng^{*}  and Yu Wang^{*} 

[그림 3] 난소암 진단 및 치료 분야 대규모 언어 모델(LLM) 벤치마킹에 대한 타 연구⁷

이 연구와 같이 LLM이 암 진단에 효과적이라는 것을 증명한 선행 연구는 많이 있지만, 실제 환자의 멀티모달 데이터를 입력받아 진단-예후-근거가 포함된 보고서를 생성하는 End-to-End 시스템은 아직 없다. 우리 연구가 성공적이라면 인간의 질병 중 가장 중요한 암을 AI로 진단하고 AI의 예측 결과를 기반으로 임상 보고서를 생성하여 임상에서의 적용 가능성을 높인 유의미한 연구가 될 것이다.

C. 제안 내용

1. 연구 과제에서 다루는 문제점

a. 난소암의 조기 진단과 악성 위험도 평가의 어려움

난소암은 초기 증상이 뚜렷하지 않아 조기 발견이 어렵고, 진단 시기가 늦어질수록 예후가 급격히 악화되는 대표적인 고위험 암종이다. 특히 난소 종양은 양성, 경계성, 악성으로 이어지는 계층적 특성을 가지므로, 단순한 이진 분류를 넘어 종양의 악성 가능성과 세부 위험도를 정밀하게 판단하는 기술이 필요하다. 그러나 실제 임상에서는 이러한 판단이 영상 판독자와 의료진의 경험에 크게 의존하고 있어 일관성과 객관성이 충분히 확보되지 못하고 있다.

b. 단일 모달리티 기반 진단의 한계

현재 난소암 진단에는 초음파, CT와 같은 의료영상과 함께 연령, 바이오마커, 폐경 여부 등 다양한 임상 정보가 함께 활용된다. 하지만 기존의 많은 인공지능 연구는 영상 또는 임상 데이터 중 하나의 모달리티만 사용하는 경우가 많아, 실제 임상에서 활용되는 복합적 판단 구조를 충분히 반영하지 못한다. 이로 인해 종양의 형태학적 특징과 환자의 임상적 특성을 동시에 고려해야 하는 난소암 진단 문제를 정밀하게 다루는 데 한계가 있다.

⁷ Cai, H., Wang, C., Zhang, Y., Ding, H., Hong, W., Zhao, Y., Cheng, S., & Wang, Y. (2026). Decoding AI competence: Benchmarking large language models (LLMs) in ovarian cancer diagnosis and treatment—A systematic evaluation of generative AI accuracy and completeness. *Diagnostics*, 16(4), 616. <https://doi.org/10.3390/diagnostics16040616>

c. 재발 예후 예측의 부족

난소암은 치료 이후에도 높은 재발률을 보이는 질환으로, 단순히 현재의 양성·악성 여부를 예측하는 것만으로는 충분하지 않다. 초기 진단 단계에서부터 재발 위험을 함께 예측할 수 있다면 치료 전략 수립과 환자 관리에 큰 도움이 되지만, 기존 연구는 주로 진단 또는 분류 성능 자체에 집중되어 있어 진단과 예후 예측을 통합적으로 다루는 사례가 제한적이다.

d. AI 예측 결과의 해석 가능성과 임상 활용성 부족

기존 의료 AI 모델은 높은 예측 성능을 보이더라도, 출력 결과가 단순 확률값이나 클래스 예측에 머무는 경우가 많아 의료진이 실제 임상 현장에서 활용하기 어렵다. 특히 의료 현장에서는 예측 결과 자체뿐 아니라, 그 결과를 어떤 근거로 판단했는지, 이를 환자 상태와 어떻게 연결해 해석할 수 있는지가 중요하다. 따라서 예측 결과를 구조화된 보고서 형태로 제공하여 의료진의 의사결정을 지원할 수 있는 시스템이 필요하다.

2. 문제 해결을 위한 제안 내용

본 연구는 앞서 기술한 네 가지 문제점을 해결하기 위해, CT 영상과 임상 데이터를 통합한 멀티모달 AI기반의 난소암 계층적 진단·재발 예후 예측 및 임상 보고서 자동 생성 시스템을 제안한다.

a. 계층적 진단 모델을 통한 정밀 위험도 평가

- 단순 이진 분류에 머무르지 않고, 양성/악성 판별에서 조직학적 아형(subtype) 분류로 이어지는 계층적 예측 구조를 설계한다.
- 종양의 악성 가능성과 세부 위험도를 단계적으로 판단함으로써, 경험에 의존한 주관적 판독을 보완하고 일관되고 객관적인 진단 보조 기능을 제공한다.
- Grad-CAM 기반 시각화를 통해 모델이 판단에 활용한 영상 내 근거 영역을 의료진에게 직관적으로 제시한다.

b. 멀티모달 융합을 통한 복합 진단 구조 구현

- CT 영상과 임상 데이터(혈액 검사 수치, 병력, 병기 등)를 각각 독립적인 인코더로 처리한 후, 멀티모달 융합 모듈에서 통합하는 구조를 채택한다.
- Concatenation, cross-attention, contrastive learning 등 다양한 융합 전략을 실험적으로 비교하여 최적의 방법을 적용함으로써, 실제 임상 of 복합적 판단 구조를 AI 모델에 반영한다.
- 단일 모달리티 기반 모델 대비 진단 정확도 향상을 기대하며, 영상 정보와 임상 정보의 상호보완적 활용을 목표로 한다.

c. 진단과 재발 예측의 통합 파이프라인 구축

- 종양의 양성/악성 진단 및 아형 분류와 함께, 멀티모달 융합 표현을 활용한 재발 위험 예측을 단일 end-to-end 파이프라인 내에서 통합적으로 수행한다.
- 초기 진단 단계에서부터 재발 위험도를 정량적으로 예측함으로써, 치료 전략 수립과 사후 환자 관리에 실질적인 근거를 제공한다.

d. RAG-LLM 기반 임상 보고서 자동 생성

- 예측 결과(양성/악성 여부, 조직학적 아형, 재발 위험도)와 환자 정보를 바탕으로, RAG(Retrieval-Augmented Generation) 기법을 활용하여 구조화된 임상 보고서를 자동으로 생성한다.
- 의료 문헌 DB로 구성된 Knowledge Base에서 관련 근거를 검색·결합함으로써 LLM의 환각(hallucination) 문제를 완화하고, 의학적 근거에 기반한 신뢰도 높은 보고서를 제공한다.
- 단순 확률값 출력을 넘어 의료진이 임상 현장에서 직접 활용 가능한 형태의 결과물을 제시함으로써, AI 모델의 실용적 임상 활용성을 높인다.

D. 기대 효과 및 의의

1. 기대효과

a. 난소암 진단 정확도 및 일관성 향상

CT 영상과 임상 정보를 통합하여 활용함으로써, 기존의 단일 모달리티 기반 모델보다 더 정확하고 일관된 악성 위험도 평가가 가능할 것으로 기대된다. 이는 판독자의 경험에 따라 발생할 수 있는 진단 편차를 줄이고, 보다 객관적인 의사결정 지원을 가능하게 한다.

b. 조기 진단 및 맞춤형 치료 전략 수립 지원

난소 종양의 악성 가능성을 정밀하게 예측하고, 나아가 재발 위험까지 함께 평가할 수 있다면 조기 진단과 함께 환자별 맞춤형 치료 전략 수립에 기여할 수 있다. 특히 수술 여부, 상급 병원 의뢰, 추적관찰 강도 결정 등 주요 임상 판단 과정에서 실질적인 보조 도구로 활용될 수 있다.

c. AI 결과의 임상 활용성 증대

LLM 기반 임상 보고서 생성 기능을 결합함으로써, AI 모델의 예측 결과를 의료진이 이해하고 활용하기 쉬운 형태로 제공할 수 있다. 이는 단순한 분류 모델을 넘어 실제 임상 workflow에 통합 가능한 AI 시스템으로 발전할 수 있는 가능성을 보여준다.

d. 난소암 특화 멀티모달 AI 연구의 선도적 사례 제시

기존의 많은 연구가 흉부 X-ray, 뇌 MRI 등 특정 영역에 집중되어 있는 반면, 본 연구는 난소암이라는 고난도 질환을 대상으로 영상과 임상정보를 통합하고, 더 나아가 보고서 생성까지 포함하는 통합 파이프라인을 제안한다. 따라서 본 연구는 난소암 특화 멀티모달 AI의 선도적 사례로서 의미를 가질 수 있다.

2. 연구의 의의

본 연구의 의의는 다음과 같다.

첫째, 본 연구는 난소암 진단 문제를 단순 분류가 아닌 계층적 진단 및 예후 예측 문제로 확장하여 다룬다는 점에서 의의가 있다. 이는 실제 임상 의사결정 구조를 보다 충실히 반영하는 접근이다.

둘째, 의료영상과 임상 데이터를 통합하는 멀티모달 프레임워크를 통해, 기존 단일 모달리티 기반 연구의 한계를 보완하고 보다 정밀한 진단 체계를 제안한다는 점에서 학술적 가치가 있다.

셋째, LLM 기반 임상 보고서 생성 기능을 결합한 통합형 AI 시스템을 지향함으로써, 단순한 예측 모델을 넘어 실제 의료 현장에서 활용 가능한 형태로 확장하려는 시도를 담고 있다는 점에서 차별성이 있다.

마지막으로, 멀티모달 데이터를 활용한 난소암 계층적 진단 및 예후 예측에 더하여 LLM 임상 보고서 생성까지의 프레임워크를 제시함으로써 난소암 관련 후속 연구 및 실제 임상 적용으로 연결될 수 있는 기반 연구라는 점에서 중요한 의의를 가진다.

E. 주요 기능 리스트

1. CT 영상 기반 병변 특징 추출 기능

본 기능은 CT 영상으로부터 난소 종양의 경계, 형태학적 구조 등 악성 여부 판단에 중요한 시각적 특징을 자동으로 추출하는 기능이다. 기존 임상에서는 CT 판독이 검사자 숙련도와 경험에 따라 달라질 수 있어 동일 병변에 대해서도 해석의 차이가 발생할 수 있다. 이를 해결하기 위해 본 연구에서는 ResNet50 및 ViT 기반 이미지 인코더를 활용하여 영상 내 주요 특징을 정량화된 latent representation 형태로 추출한다. 이를 통해 영상 판독의 주관성을 줄이고, 난소 종양의 악성 가능성을 일관된 기준으로 평가할 수 있는 기반을 마련한다.

2. 임상 데이터 기반 환자 위험도 표현 학습 기능

본 기능은 환자의 연령, 혈액 바이오마커, 폐경 여부, 임신 여부 등 구조화된 임상 데이터를 입력받아 환자의 상태를 반영하는 임상적 특징 벡터를 생성하는 기능이다. 난소암 진단은 영상 정보만으로 이루어지지 않으며, 환자의 생리적·임상적 상태가 함께 고려되어야 보다 정확한 판단이 가능하다. 따라서 임상 데이터를 함께 활용함으로써 영상만으로 포착하기 어려운 환자별 위험 요인을 반영하여 전체 예측 성능을 보완하는 역할을 수행한다.

3. 멀티모달 특징 융합 기능

본 기능은 CT 영상에서 추출된 특징과 임상 데이터에서 추출된 특징을 결합하여 하나의 통합된 질병 표현으로 구성하는 기능이다. 난소암은 영상적 특징과 임상적 특징이 복합적으로 작용하는 질환이므로, 단일 모달리티 기반 예측만으로는 실제 임상 판단 구조를 충분히 반영하기 어렵다. 본 연구에서는 Concatenation, Cross-attention, Contrastive-learning 등의 기법을 적용하여, 두 모달리티의 정보를 통합할 수 있는 방식을 검증한다.

4. 난소 종양 양성·악성 예측 기능 & 계층적 진단 기능

본 기능은 단순한 양성·악성 이진 분류에 머무르지 않고, 향후 subtype 계층적 진단 구조를 반영하여 예측 구조를 제공하는 기능이다. 난소 종양은 단순히 악성과 양성으로만 구분되지 않으며, 경계성 종양이나 조직학적 아형에 따라 치료 전략과 추적 관찰 방식이 달라질 수 있다. 따라서 본 연구의 모델은 현재 단계에서는 이진 분류를 우선 수행하되, 이후 보다 세분화된 진단 과제로 자연스럽게 확장될 수 있도록 구조적으로 설계된다.

5. 재발 예후 예측 확장 기능

본 기능은 초기 진단 결과와 환자의 임상적 특성을 함께 고려하여 향후 재발 위험도를 예측할 수 있도록 설계된 기능이다. 난소암은 초기 치료 이후에도 높은 재발률을 보이는 질환이므로, 단순 진단 정확도 향상만으로는 임상적 요구를 충분히 충족하기 어렵다. 본 연구는 멀티모달 기반 진단 결과를 바탕으로 재발 가능성까지 예측할 수 있는 구조를 포함함으로써, 환자별 위험도 기반 추적관리와 치료 계획 수립을 지원하는 방향으로 확장성을 확보한다.

6. 예측 근거 제시 및 설명 가능성 지원 기능

본 기능은 모델이 어떤 영상 특징과 어떤 임상 변수를 바탕으로 예측을 수행했는지 설명 가능한 형태로 제시하는 기능이다. 의료 AI는 단순히 정확도가 높은 것만으로는 실제 임상 적용이 어렵고, 예측의 근거를 의료진이 이해할 수 있어야 한다. 본 연구에서는 향후 Grad-CAM 기반 시각화^와 [feature importance 분석](#)을 활용하여, 영상에서 주목한 영역과 임상 변수의 상대적 기여도를 제시할 수 있도록 설계한다. 이를 통해 AI 모델의 해석 가능성을 높이고, 의료진의 신뢰 확보에 기여한다.

7. LLM 기반 임상 보고서 자동 생성 기능

본 기능은 멀티모달 모델이 도출한 진단 결과와 예후 예측 결과를 바탕으로, 이를 자연어 형태의 구조화된 임상 보고서로 자동 생성하는 기능이다. 기존 AI 모델은 예측 결과를 숫자나 클래스 형태로만 제시하는 경우가 많아 실제 임상에서 바로 활용하기 어렵다. 반면 본 연구는 예측 결과와 그 근거를 요약하여 LLM이 임상 보고서 형식으로 정리하도록 함으로써, 의료진이 보다 쉽게 결과를 해석하고 활용할 수 있도록 한다. 이는 단순 분류 모델을 넘어 실제 임상 workflow에 가까운 형태로 발전시키기 위한 핵심 기능이다.

III. 과제 설계

A. 요구사항 정의

본 프로젝트는 난소암 CT 영상과 환자의 임상 데이터를 통합하여 진단의 정확도를 높이고, 환자의 예후(재발 여부)를 예측하는 지능형 의료 보조 시스템 구축을 목표로 한다. 이를 위해 다음과 같이 기능적, 비기능적, 사용자 요구사항을 정의한다.

1. 기능적 요구사항

시스템이 제공해야 하는 핵심 동작 및 데이터 처리 기능이다.

a. 다단계 종양 분류(Cascade Tumor Classification)

- i. 이진 분류: 입력된 CT 영상을 분석하여 양성과 악성 여부를 우선적으로 판별해야 한다.
- ii. 다중 분류: 악성으로 판정된 샘플에 한해, 조직학적 특징에 따른 5종의 세부 서브타입(Serous, Mucinous 등)을 추가로 분류해야 한다.

b. 멀티모달 데이터 융합(Multi-modal Data Fusion)

- i. 데이터 통합: 비정형 영상 데이터(CT)와 정형 임상 데이터(나이, CA-125 수치 등 텍스트 피쳐)를 단일 모델 내에서 결합하여 분석에 활용해야 한다.

c. 재발 확률 예측 (Recurrence Prediction)

- i. 예후 진단: 영상의 형태학적 정보와 환자의 생리학적 지표를 종합하여, 향후 환자의 재발 가능성을 확률값으로 도출해야 한다.

d. 핵심 슬라이스 선별 (Slice Attention)

- i. 가중치 산출: 환자 당 8장의 CT 슬라이스 중 병변의 특징이 가장 잘 드러나는 핵심 슬라이스를 모델이 스스로 식별하고 가중치를 부여해야 한다.

e. 종양 위치 식별 및 정량화(Tumor Localization)

- i. 위치 특징: CT 영상 내에서 종양의 해부학적 위치(예: 좌측/우측 난소 등)를 식별하여 텍스트 및 좌표 정보로 도출해야 한다.

f. 통합 진단 리포트 자동 생성

- i. 양/악성 판정, 서브타입, 재발 확률과 함께 종양의 주요 위치 정보를 결합한 종합 진단 리포트를 생성해야 한다.

2. 비기능적 요구사항

시스템의 성능, 안정성 및 품질에 관한 요구사항이다.

- a. 성능 지표로서의 진단 신뢰성 확보: 의료 데이터의 불균형을 고려하여 Accuracy 외에도 AUC, F1-score, Recall 지표를 병행 평가지표로 활용하며, 각 지표의 최적화를 달성해야 한다.


- b. **학습 전략으로서의 검증 및 효율성**: 데이터 부족 문제를 해결하기 위해 사전 학습된 Backbone 모델을 사용하며, 5-Fold Cross Validation을 통해 모델의 일반화 성능을 검증해야 한다.
- c. **전처리 표준화**: 서로 다른 도메인의 데이터를 통합하기 위해 각 피처별 정규화 및 스케일링 작업이 선행되어야 한다.

3. 사용자 요구사항

실제 의료 현장의 사용자(의료진 및 환자) 관점에서의 요구사항이다.

- a. **AI 판단 근거 제시**: 모델의 내부 동작을 시각화하기 위해 슬라이스별 Attention Weight를 도출하고, 의료진 및 환자가 육안으로 진단 근거를 확인할 수 있는 인터페이스를 제공해야 한다.
- b. **통합 리포트 제시**: 한 번의 분석 프로세스를 통해 [양/악성 판정, 서브타입 분류, 재발 위험도, 종양 위치]라는 4가지 통합 진단 결과를 **환자에게** 동시에 제공하여 진단 효율성을 극대화 해야한다.

B. 전체 시스템 구성



[그림 4] 전체 시스템 구성도

본 시스템은 CT 영상과 입상 데이터를 입력으로 받아, 난소 종양의 계층적 진단과 재발 예측을 수행하고, 최종적으로 LLM 기반 임상보고서를 자동 생성하는 end-to-end AI 파이프라인으로 구성된다. 전체 구조는 입력층, 인코더층, 계층적 예측 모듈, 멀티모달 융합 및 재발 예측 모듈, **YOLO 기반 종양 위치 탐지 모듈**, 보고서 생성 모듈의 6단계로 이루어진다.

1) 입력층

- CT 영상 (PNG 형식)과 정형 입상 데이터(혈액 검사 수치, 키, 몸무게 등) 두 가지 모달리티를 입력으로 사용한다.
- 두 모달리티는 각각 독립적인 인코더로 분기되어 처리된다.

2) 인코더층

- CT 이미지 인코더 : CNN 또는 ViT(Vision Transformer) 기반으로 영상에서 고차원 특징 벡터를 추출한다.
- 임상 데이터 인코더 : MLP를 기반으로 정형 데이터를 특징 벡터로 변환한다.
- 각 인코더는 해당 모달리티의 특성에 맞게 독립적으로 설계하여 모달리티별 최적 표현 학습을 목표로 한다.

3) 계층적 예측 모듈

- CT 이미지 인코더의 출력 벡터를 기반으로 두 단계의 계층적 분류를 수행한다.
- 1단계: 종양의 양성/악성 여부를 이진 분류(binary classification)한다.
- 2단계: 악성으로 판별된 경우, 조직학적 아형(subtype)을 다중 분류(multiclass classification)한다.
- Grad-CAM을 적용하여 모델 판단 근거가 되는 영상 내 관심 영역을 시각화함으로써 예측 결과의 해석 가능성(explainability)을 제공한다.

4) 멀티모달 융합 및 재발 예측 모듈

- CT 이미지 인코더와 임상 데이터 인코더의 출력 벡터를 멀티모달 융합 모듈에서 통합한다.
- 융합 방식은 단순 연결(concatenation), cross-attention, contrastive learning 등 여러 전략을 실험적으로 비교하여 최적의 방법을 채택할 예정이다.
- 융합된 표현을 바탕으로 치료 후 재발 위험을 예측하여, 영상 정보와 임상 정보를 동시에 고려한 정량적 예후 예측이 가능하다.

5) YOLO 기반 종양 위치 탐지 모듈

- CT 영상을 입력으로 받아 YOLOv8 기반 객체 탐지 모델이 종양 의심 영역의 bounding box를 자동으로 탐지한다.
- 탐지된 bounding box로부터 병변의 위치(영상 기준 좌/중/우, 상/중/하), 크기(픽셀 및 면적 비율), 탐지 신뢰도(confidence)를 추출하고, 이를 임상적으로 해석 가능한 텍스트로 변환한다.
- 본 모듈은 분류 모델 및 재발 예측 모듈과 독립적으로 동작하며, 추론 단계에서 두 모델의 예측 결과와 병합되어 구조화된 텍스트 형태로 LLM 기반 보고서 생성 모듈에 전달된다.
- 이를 통해 단순 예측 수치뿐만 아니라 병변의 위치 및 크기 정보를 포함한 근거 기반 보고서 생성이 가능하다.

6) 보고서 생성 모듈

- 양성/악성 여부, 조직학적 아형, 재발 위험 예측 결과와 Grad-CAM, YOLO 기반 종양 위치 탐지 결과를 종합하여 RAG-LLM 기반 임상 보고서 자동 생성 모듈로 전달한다.

- **faissDB**에서 관련 근거를 검색(retrieval)하고, 이를 예측 결과 및 환자 정보와 결합하여 구조화된 임상 보고서를 생성한다.
- RAG(Retrieval-Augmented Generation) 기법을 통해 LLM의 환각(hallucination) 문제를 완화하고, 의학적 근거에 기반한 신뢰도 높은 보고서 생성을 목표로 한다.

C. 주요 엔진 및 기능 설계

1. 준지도학습 기반 멀티모달 융합 모델을 활용한 난소암 악성도 및 재발 예측

a. 목적

본 모듈의 목적은 난소암 환자의 복부 CT 영상과 임상 데이터를 결합하여 (1) 종양의 악성 여부(Malignancy)와 (2) 수술 후 재발 여부(Recurrence)를 동시에 예측하는 멀티태스크·멀티모달 딥러닝 모델을 개발하는 것이다. 재발 예측은 수술 후 추가 치료 계획 수립 및 고위험 환자 조기 추적 관찰에 직접적으로 활용될 수 있으며, 악성 여부 예측은 이미지 인코더의 표현력 강화를 위한 보조 학습 신호로 사용된다. 전체 데이터 중 재발 라벨이 존재하는 환자(Labeled)가 소수이고, 재발 라벨 없이 악성 여부 라벨만 존재하는 환자(Unlabeled)가 다수인 준지도학습(Semi-Supervised Learning) 환경을 가정하여 설계되었다.

b. 방법

i. 데이터 구성

- 입력 데이터: 환자당 8장의 CT 슬라이스($224 \times 224 \times 3$)와 9개의 임상 피처(나이, 키, 몸무게, CA-125, PT_GVD, PT_Para, 진단 시 연령, 초음파 및 CT 촬영 시점 등)를 사용한다.
- 라벨 구조: 재발 라벨(0/1)이 존재하는 Labeled 환자와, 재발 라벨이 없고(-1) 악성 여부 라벨만 존재하는 Unlabeled 환자로 구성된다.

Label	환자 수
재발 (1)	187명 (7.3%)
재발 없음 (0)	753명 (29.3%)
모름/결측 (-1)	1622명 (63.2%)
전체 (골반 CT를 가진 환자 수)	2562명

[표 2] 재발 여부 라벨 분포

- 데이터 분할: 5-Fold Cross-Validation을 적용하였으며, 환자 단위로 fold를 분리하여 데이터 누수를 방지하였다.

ii. 모델 아키텍처

MultiModalBinaryFusionModel은 이미지 인코더와 임상 데이터 인코더를 결합한 멀티모달 구조로, 두 가지 예측 헤드를 가진다.

- 이미지 인코더: 3종의 백본(ResNet50, ViT-B/16, CNN-Transformer Hybrid)을 실험적으로 비교하였다. Hybrid 모델은 ResNet50으로 슬라이스별 특징을 추출한 뒤 Transformer Encoder를 통해 슬라이스 간 관계를 학습하는 구조이다.
- 임상 데이터 인코더: TabularMLP Encoder(256→128→16)를 사용하여 임상 피처를 저차원 벡터로 압축한다.
- 멀티모달 융합(Fusion) 방법: 이미지 특징과 임상 특징을 융합하기 위해 Concatenation 기반 Fusion 전략을 채택하였다. 이미지 특징은 image_proj (Linear → ReLU → LayerNorm → Dropout)를 통해 256차원으로 투영되고, 임상 특징은 tab_proj (Linear → ReLU → LayerNorm → Dropout)를 통해 정제된 후 L2 정규화된다. 두 특징을 Concatenate한 뒤 Fusion Head (Linear → ReLU → LayerNorm → Dropout → Linear)를 통해 최종 예측을 수행한다. 학습 안정성을 위해 임상 피처에 Tab Drop(p=0.9)과 Tab Scale(0.1)을 적용하여 이미지 특징에 대한 과도한 의존을 방지하였다.
- 재발 예측 헤드(Fusion Head): 이미지 특징과 임상 특징을 결합(Concatenate)하여 재발 여부를 예측한다. 학습 안정성을 위해 임상 피처에 Tab Drop(p=0.9)과 Tab Scale(0.1)을 적용하여 이미지 특징에 대한 과도한 의존을 방지하였다.
- 악성 예측 헤드(Malignancy Head): 이미지 특징만을 입력으로 받아 악성 여부를 예측한다.

iii. 준지도학습 (semi-supervised learning) : Mean Teacher

재발 라벨이 없는 Unlabeled 데이터, 즉 재발 라벨이 모름/결측(-1)인 환자들의 데이터를 활용하기 위해 Mean Teacher 방식을 적용하였다.

- Student 모델은 일반적인 역전파로 학습하며, Teacher 모델은 Student 파라미터의 EMA(Exponential Moving Average)로 갱신된다(decay=0.999).
- Unlabeled 데이터에 대해 Student와 Teacher의 재발 예측 확률 간 MSE를 Consistency Loss로 정의하고, Ramp-up 스케줄러를 통해 학습 초기에는 가중치를 낮추다가 점차 증가시킨다.
- 악성 여부 라벨은 Labeled·Unlabeled 모두에 존재하므로 두 데이터셋 모두에 Supervised Loss를 적용한다.

- 총 손실 함수: $L = L_{\text{rec}} + 0.3 \times L_{\text{mal}} + \lambda(t) \times L_{\text{cons}}$

iv. 학습 전략

- Optimizer: Adam (lr=5e-5, weight_decay=1e-4)
- Scheduler: ReduceLROnPlateau (factor=0.5, patience=2, min_lr=1e-6)
- 클래스 불균형 대응: BCEWithLogitsLoss의 pos_weight를 $\sqrt{(\text{neg}/\text{pos})}$ 로 계산하여 적용
- Early Stopping: val_rec_auc 기준, patience=10
- 이미지 증강: 수평 플립, $\pm 10^\circ$ 회전, 랜덤 크롭, 밝기/대비 조정, 가우시안 노이즈, 슬라이스 드롭아웃
- ImageNet 사전학습 가중치를 로컬에서 로드하며, Backbone은 초기에 Freeze 후 Layer4만 Unfreeze하여 Fine-tuning

v. 예측 결과 시각화 : Grad-CAM

모델의 예측 결과에 대한 해석 가능성을 높이기 위해 Grad-CAM (Gradient-weighted Class Activation Mapping) 기반 시각화 기능을 설계하였다.

Grad-CAM은 이미지 인코더의 마지막 합성곱 레이어(Layer4)에 대한 gradient를 활용하여 예측에 기여한 영상 내 주요 영역을 히트맵 형태로 시각화한다. 환자당 8개의 CT 슬라이스 각각에 대해 독립적으로 Grad-CAM을 계산하며, 생성된 히트맵은 원본 CT 영상에 오버레이되어 시각적 근거로 제공된다. 이를 통해 모델이 악성도 및 재발 예측 시 CT 영상의 어느 영역을 주요 판단 근거로 활용했는지 직관적으로 확인할 수 있다. 또한 Transformer 기반 모델에서는 슬라이스별 Attention Weight를 함께 시각화하여, 8개 슬라이스 중 모델이 상대적으로 중요하게 판단한 슬라이스를 강조하도록 설계하였다.

c. 실험 내용

세 가지 이미지 인코더 백본(ResNet50-Fusion, ViT-Fusion, Hybrid-Fusion)에 대해 동일한 멀티모달 Fusion 구조 및 Mean Teacher 학습 파이프라인을 적용하고, 5-Fold Cross-Validation으로 성능을 비교하였다.

- 평가 지표: ROC-AUC, Sensitivity(Recall), F1-score, Accuracy, Confusion Matrix
- 재발 예측(Recurrence)과 악성 예측(Malignancy)에 대해 각각 독립적으로 평가

- 악성 예측 평가 시, 재발 라벨 유무와 악성 여부 라벨 간 강한 상관관계(재발=1인 환자의 100%가 악성)로 인한 평가 편향을 방지하기 위해, Malignancy Validation Set을 전체 환자(recurrence=0/1/-1)로 구성하였다.
- Best 모델 선택 기준: val_rec_auc (재발 예측 AUC)

d. 실험 결과

	Recurrence prediction		Malignancy prediction	
Model	ROC-AUC	Sensitivity	ROC-AUC	Sensitivity
ResNet50-Fusion	0.915 ± 0.035	0.850 ± 0.094	0.930 ± 0.015	0.858 ± 0.093
ViT-Fusion	0.912 ± 0.030	0.637 ± 0.096	0.953 ± 0.015	0.852 ± 0.044
Hybrid-Fusion	0.914 ± 0.021	0.823 ± 0.034	0.920 ± 0.023	0.930 ± 0.048

[표 1] 멀티모달 융합 모델 실험 결과

*ROC-AUC : 이진 분류 모델의 성능을 평가하는 지표로, 모든 threshold에서 FPR(False Positive Rate) 대비 TPR(True Positive Rate)의 변화를 그래프(ROC 곡선)로 그려 그 아래 면적(AUC)을 계산한다. 면적이 1에 가까울수록 모델의 분류 성능이 우수하며, 0.5는 무작위 예측 수준을 의미한다.

*Sensitivity (민감도) : 분류 모델이나 진단 검사에서 실제 양성인 사례 중 모델이 양성으로 올바르게 예측한 비율을 의미하는 평가 지표이다. Recall 또는 TPR(True Positive Rate)라고도 부르며, 특히 양성을 놓치지 않는 것이 중요한 도메인(예: 암 진단, 불량품 탐지)에서 핵심적인 성능 지표로 사용된다.

세 모델의 5-Fold 평균 재발 예측 ROC-AUC는 ResNet50-Fusion 0.915, ViT-Fusion 0.912, Hybrid-Fusion 0.914로 유사한 수준을 보였다. Sensitivity의 경우 ResNet50-Fusion(0.850)이 가장 높고, ViT-Fusion(0.637)이 가장 낮았으며, Hybrid-Fusion(0.823)은 표준편차 0.034로 fold 간 안정성이 가장 높았다. 악성 예측에서는 ViT-Fusion의 ROC-AUC가 0.953으로 가장 높았으나 재발 예측 Sensitivity가 크게 낮아지는 트레이드오프가 관찰되었다. 종합적으로 재발 예측 안정성과 Sensitivity를 고려할 때 ResNet50-Fusion 또는 Hybrid-Fusion이 임상 적용에 적합한 후보 모델로 판단된다.

e. 미진한 사항

- 단일 모달리티 대비 성능 비교 미수행: 현재 멀티모달 융합 모델(CT 영상 + 임상 데이터)에 대한 비교 실험만 수행되었으며, CT 영상 또는 임상 데이터만을 사용하는 단일 모달리티 모델과의 성능 비교 실험은 아직 수행하지 못하였다. 멀티모달 융합의 실질적인 효과를 정량적으로 검증하기 위해 향후 단일 모달리티 베이스라인 모델과의 비교 실험을 수행할 예정이다.
- 계층적 진단 구조 미완성: 초기 설계 단계에서는 악성 여부 예측 → subtype 예측으로 이어지는 계층적 진단 구조를 계획하였으나, subtype 예측 모델의 경우 데이터 부족 문제 등으로 인해 Accuracy 약 0.6, F1-score 약 0.5 수준의 낮은 성능을 보였다. 이에 현재로서는 악성 여부 진단까지만 모델에 포함시켰으며, subtype 예측 기능은 향후 충분한 데이터 확보 및 모델 개선을 통해 추가할 예정이다.
- Fusion 전략 비교 실험 미완료: 초기 설계 단계에서는 Concatenation, Cross-attention, Contrastive Learning 세 가지 융합 전략을 비교 실험하여 최적의 방법을 채택할 계획이었으나, 현재까지 Concatenation 방식만 구현 및 실험이 완료된 상태이다. Cross-attention 및 Contrastive Learning 기반 융합 방식에 대한 비교 실험은 향후 수행할 예정이다.
- Attention Weight 균등 분포 문제: Transformer 기반 모델에서 8개 슬라이스에 대한 Attention Weight가 약 12.5%씩 균등하게 분포되어, 모델이 진단에 중요한 슬라이스를 discriminative하게 구분하지 못하고 있다. Attention 정규화 또는 슬라이스 중요도 가중치 학습 방법 개선이 필요하다.
- Grad-CAM 해석 신뢰성: 현재 Grad-CAM은 학습 시 Freeze된 layer4 파라미터의 gradient를 사용하므로 활성화 맵의 신뢰성이 제한적이다. 추론 시 layer4를 일시적으로 Unfreeze하여 gradient를 계산하는 방식으로 보완하였으나, 근본적으로 GradCAM++ 또는 Score-CAM 등 대안적 해석 기법 적용을 고려할 필요가 있다.
- 임상 피쳐 기여도 분석 부재: 현재 Tab Drop 및 Tab Scale을 통해 임상 피쳐의 영향을 제한하고 있으나, 각 임상 피쳐가 예측에 기여하는 정도를 정량적으로 분석하는 SHAP 등의 해석 도구가 적용되지 않았다.
- 외부 검증 데이터셋 부재: 현재 AIHub 난소암 데이터셋에 대한 5-Fold 내부 검증만 수행되었으며, 타 데이터를 활용한 일반화 성능 검증이 이루어지지 않았다.
- Threshold 최적화 미적용: 현재 분류 임계값을 0.5로 고정하였으나, 재발 예측에서 Sensitivity를 최우선으로 할 경우 임계값 최적화(예: Youden's Index 기반)를 통한 성능 향상이 가능하다.

2. YOLO 기반 병변 위치 탐지 모듈

a. 목적

본 모듈의 목적은 난소암 환자의 복부 CT 영상에서 YOLOv8 기반 객체 탐지 모델을 활용하여 병변 의심 영역을 자동으로 탐지하고, 탐지된 병변의 위치 정보를 구조화된 형태로 추출하여 RAG 기반 임상 보고서 생성 모듈에 전달하는 것이다. 본 모듈은 분류 모델 및 재발 예측 모델과 독립적으로 동작하며, 기존 classifier용 전처리 데이터를 수정하지 않고 원본 CT PNG 영상을 직접 입력으로 사용한다.

b. 방법

i. 데이터 구성 및 라벨 변환

YOLO 모델 학습을 위해 원본 CT PNG 영상과 라벨링 JSON 파일에 포함된 polygon 좌표를 활용하였다. 기존 라벨링 데이터는 종양 경계를 다각형(polygon) 형태로 표현하고 있으므로, 이를 YOLO 학습에 적합한 bounding box 형식으로 변환하는 전처리 과정을 수행하였다. 구체적으로 polygon 좌표의 최소/최대 x, y값을 기반으로 bounding box를 계산하고, 5%의 padding을 추가하여 종양 주변 조직 정보를 포함하도록 하였다. 변환된 bounding box는 YOLO 표준 형식인 정규화된 (cx, cy, w, h) 형태로 저장된다. 너무 작은 박스(2px 미만)는 노이즈로 판단하여 제거하였다.

ii. Patient-level Train / Val split

YOLO 모델의 학습/검증 데이터 분리는 반드시 환자 단위(patient-level)로 수행하였다. 동일 환자의 여러 CT 슬라이스가 학습과 검증 데이터에 동시에 포함되는 데이터 누수(data leakage)를 방지하기 위함이다. 환자는 class_name과 patient_id를 결합한 patient_key 단위로 관리되며, 클래스별로 각각 15%의 환자를 검증 데이터로 분리하여 클래스 분포를 유지하였다. 분리 결과는 manifest 파일로 저장하여 재현성을 보장한다.

iii. 모델 학습

사전학습된 YOLOv8s 가중치를 초기값으로 사용하여 난소암 CT 영상에 특화된 파인튜닝을 수행하였다. 난소암 병변은 단일 클래스(lesion)로 정의하여 single_cls=True로 학습하였다. 주요 학습 설정은 다음과 같다.

- 입력 이미지 크기: 512×512
- Epochs: 50 (Early Stopping patience=15)
- Batch size: 16
- Optimizer: Adam (기본값)
- Confidence threshold: 0.25

iv. 위치 정보 추출 및 구조화

학습된 YOLO 모델은 신규 CT 영상이 입력되면 병변 의심 영역의 bounding box 좌표(x1, y1, x2, y2), confidence score, 병변 중심 좌표, 병변 크기(픽셀 및

면적 비율)를 추출한다. 추출된 수치 정보는 임상적으로 해석 가능한 텍스트로 변환된다. 구체적으로 병변 중심 좌표를 영상 전체 크기 대비 상대적 위치로 계산하여 "영상 기준 좌측/중앙/우측", "상방/중간/하방" 형태의 위치 설명을 생성하고, 병변 크기는 전체 영상 면적 대비 비율로 소형/중형/대형으로 분류한다.

v. **추론 파이프라인 연동**

본 모듈은 분류 모델 및 재발 예측 모델과 독립적으로 동작하며, 추론 단계에서 두 모델의 결과와 병합되어 RAG 모듈로 전달된다. 신규 환자의 CT 영상이 입력되면 분류 모델은 악성/양성 및 재발 예측 결과를 생성하고, YOLO 모듈은 동일 영상에서 병변 위치 정보를 추출한다. 두 결과는 구조화된 텍스트(bbox_text)로 통합되어 Qwen 2.5 기반 RAG 모듈의 프롬프트 컨텍스트로 활용된다.

3. Retrieval-Augmented Generation (RAG) 기반 임상 보고서 생성

a. **목적**

본 모듈의 목적은 멀티모달 난소암 진단 및 재발 예측 결과를 기반으로, 환자 상태를 설명하는 임상 보고서를 자동 생성하는 것이다. 전체 시스템은 크게 예측 모델 연동 모듈, FAISS 기반 근거 검색 모듈, LLM 기반 임상 보고서 생성 모듈, YOLO 기반 병변 탐지 및 시각화 모듈로 구성된다.

b. **방법**

i. **예측 모델 연동 모듈**

환자의 임상 정형 데이터와 CT 영상 데이터를 기반으로 도출된 악성/양성 예측 결과와 재발 예측 결과를 보고서 생성 단계로 전달하는 역할을 한다. 이 모듈은 단순히 모델의 예측값만 전달하는 것이 아니라, 병변 위치, 예측 클래스, 예측 결과 요약, 영상 참고 소견 등 보고서 작성에 필요한 핵심 정보를 구조화하여 후속 모듈에서 사용할 수 있도록 한다.

ii. **FAISS 기반 근거 검색 모듈**

난소암 관련 임상 가이드라인과 연구 논문을 벡터 DB에 저장하고, 환자 상태와 관련성이 높은 문서를 검색하는 역할을 한다. 본 연구에서는 NCCN, NICE 등 공신력 있는 기관의 난소암 진료 가이드라인과 ESMO 가이드라인, Journal of Ovarian Research 등에 게재된 난소암 관련 연구 자료를 중심으로 벡터 DB를 구성하였다. 문서는 chunk 단위로 분할된 뒤 embedding 모델을 통해 벡터화되며, FAISS 인덱스에 저장된다. 이후 환자의 병변 위치, 악성/양성 예측

결과, 재발 가능성, 영상 소견 등을 바탕으로 검색 query를 생성하고, 이와 의미적으로 유사한 근거 문서를 검색한다.

iii. LLM 기반 임상 보고서 생성 모듈

예측 모델에서 전달받은 환자 정보와 FAISS 검색 모듈에서 반환된 근거 문서를 함께 입력으로 받아 환자 맞춤형 임상 보고서를 생성한다. 본 연구에서는 외부망 접근이 제한된 안심존 서버 환경을 고려하여 OpenAI API와 같은 외부 API를 사용하지 않고, Hugging Face 기반의 로컬 LLM을 활용하는 방식을 채택하였다. 현재 Llama 2, Llama 3, Qwen2.5-1.5B-Instruct, Qwen 3.5-0.8B 모델을 대상으로 보고서 생성 결과를 비교하였으며, 그중 Qwen 3.5-0.8B 모델이 한국어 문장 생성의 자연스러움과 환자 정보에 기반한 근거 반영 측면에서 상대적으로 우수한 결과를 보였다.

iv. YOLO 기반 병변 탐지 및 시각화 모듈

CT 영상 내 병변 의심 영역을 탐지하고, 해당 영역을 bounding box 또는 시각적 표시 형태로 PNG 이미지에 저장하는 기능을 담당한다. 이 모듈은 최종 임상 보고서에 시각적 근거를 함께 첨부하기 위한 목적으로 설계되었다. 이를 통해 사용자는 단순한 예측 결과뿐만 아니라, 모델이 영상의 어느 부분을 주요 판단 근거로 활용했는지 직관적으로 확인할 수 있다.

c. 실험 결과

현재까지 구현된 결과, FAISS 기반 검색 모듈은 환자 상태와 관련된 가이드라인 및 논문 근거를 검색할 수 있었고, LLM 기반 보고서 생성 모듈은 검색된 근거와 예측 결과를 바탕으로 한국어 임상 보고서를 생성할 수 있었다.

아래는 Qwen3.5-0.8B 모델로 생성된 임상 보고서 결과이다.

=====

환자 정보 / AI 예측 요약

=====

- 병변 원문 위치: Right Ovary
- 정리된 병변 위치: 우측
- 악성/양성 예측: 악성 가능성이 있는 병변
- 재발 관련 예측: 재발 가능성을 고려해야 하는 상태
- 영상 참고 소견: Suspected peritoneal metastasis near right ovary.

[AI 예측 결과 요약]

AI 모델은 병변 위치를 우측으로 정리했고, 전체 예측 결과는 '악성 가능성이 있는 병변'에 가깝게 해석됩니다. 재발 관련 판단은 '재발 가능성을 고려해야 하는 상태'로 정리됩니다. 영상 참고 소견은 'Suspected peritoneal metastasis near right ovary.'입니다.

=====

검색된 근거 출처 목록

=====

S1: D3_ksgo_2018.pdf, 2018
S2: review, P13_Follow-up_strategies_in_ovarian_cancer.pdf, 2023
S3: D10_NCCN_2026.pdf, 2026
S4: NICE, Ovarian cancer: recognition and initial management, 2023
S5: Nature Reviews Disease Primers, Ovarian cancer, 2016
S6: NCCN Guidelines for Patients: Ovarian Cancer, 2025

=====

환자용 AI 예측 설명 보고서

=====

환자용 AI 예측 설명 보고서

1. 이번 AI 예측 결과 요약

AI 모델은 우측 부위의 병변을 '악성 가능성이 있는 병변'으로 해석했습니다. 현재 입력된 정보에서는 재발 관련 판단도 '재발 가능성을 고려해야 하는 상태'로 정리됩니다. 다만 이 결과는 AI 기반 참고 자료이며, 확정 진단은 아닙니다.

2. 병변 위치와 영상 참고 소견

병변 위치는 우측으로 정리됩니다.

영상 참고 소견에는 우측 난소 주변 복막 전이가 의심된다는 내용이 포함되어 있으나, 이는 AI 기반 참고 결과이므로 담당 의료진의 영상 판독과 추가 평가가 필요합니다.

3. 검색된 논문/가이드라인에서 확인된 내용

- 난소암의 최종 진단은 영상 결과만으로 단정하기보다 조직검사, 수술 검체, 병리학적 확인 등을 통해 이루어질 수 있습니다. [출처: S3]
- 수술 후 난소암으로 진단되었거나 병기 설정 정보가 충분하지 않은 경우, 추가 진단 평가와 병리 검토가 필요할 수 있습니다. [출처: S1]
- 난소암 치료 후 추적관찰 전략에 대해서는 정기 검진이 생존 기간을 늘리는지에 대한 근거가 제한적일 수 있어, 환자 상태에 맞춘 확인이 필요합니다. [출처: S2]
- 치료 후에는 재발과 관련될 수 있는 증상 변화, 신체 상태 변화, 치료 부작용 등에 대해 의료진과 상의하는 것이 중요하게 언급됩니다. [출처: S4]

4. 의료진과 추가로 확인할 수 있는 부분

- 현재 AI 결과가 실제 악성 병변을 의미하는지는 영상 판독, 병리 결과, 임상 정보 등을 함께 검토해 의료진과 확인할 수 있습니다. [출처: S3]

- 추적관찰 과정에서는 재발 의심 증상뿐 아니라 치료 부작용, 정서적 어려움, 삶의 질 관리에 대해서도 의료진과 상의할 수 있습니다. [출처: S4]

5. 꼭 기억할 점 이 보고서는 AI 예측 결과와 검색된 문헌을 바탕으로 만든 참고용 설명입니다. 확정 진단이나 치료 결정은 담당 의료진의 진료, 검사 결과, 병리 결과를 종합해 이루어져야 합니다.

d. 미진한 사항 및 향후 계획

- 생성된 보고서는 실제 임상 보고서로 사용하기에는 아직 한계가 있었다. 임상 보고서에서 중요하게 다뤄지는 환각 문제를 아직 검증하지 못 했기 때문에 아직 신뢰성 있는 임상 보고서라고 하기는 어렵다.
- 현재 RAG-LLM 기반 보고서 생성 모듈은 독립적으로 구현된 상태이며, 준지도학습 기반 멀티모달 융합 모델(재발 예측 및 악성도 예측 모델)의 실제 예측값을 이어받아 임상 보고서를 생성하는 end-to-end 연동은 아직 구현되지 않았다. 향후 두 모듈 간 인터페이스를 정의하고 예측 결과가 보고서 생성 모듈로 자동 전달되는 통합 파이프라인을 구현할 예정이다.
- 또한 향후에는 벡터 DB에 포함되는 가이드라인 및 논문 자료를 확장하고, 더 큰 규모의 오픈소스 LLM 또는 최신 Qwen 계열 모델을 추가 비교하여 보고서 생성 성능을 개선할 계획이다. 의료 분야에서 생성형 AI의 환각 문제는 매우 중요한 한계이므로, LLM이 임의의 의학적 판단을 생성하지 않도록 프롬프트를 제한하고, 반드시 FAISS DB에서 검색된 근거 문서에 기반하여 보고서를 작성하도록 설계할 예정이다. 생성된 보고서는 문장 자연스러움, 보고서 구조의 완성도, 임상 표현의 적절성뿐만 아니라, 보고서 내 주요 claim이 검색된 가이드라인 또는 논문 내용에 의해 실제로 뒷받침되는지를 함께 평가할 계획이다.

D. 주요 기능의 구현

본 연구에서는 난소암 환자의 CT 영상과 임상 데이터를 통합하여 악성도 및 재발 여부를 예측하고, 예측 결과를 근거 기반 임상 보고서로 자동 생성하는 end-to-end AI 시스템의 구현을 목표로 하였다. 전체 시스템은 크게 세 가지 기능으로 구성된다. 첫째, 준지도학습 기반 멀티모달 융합 모델을 통한 악성도 및 재발 예측 기능, 둘째, YOLO 기반 병변 탐지 및 Grad-CAM 기반 시각적 근거 제시 기능, 셋째, FAISS 기반 RAG 검색과 LLM을 결합한 임상 보고서 자동 생성 기능이다.

현재까지 각 기능은 독립적인 모듈 단위로 구현 및 실험이 완료되었다. 예측 모델은 5-Fold Cross-Validation을 통해 성능 검증이 이루어졌으며, FAISS 기반 검색 모듈과 LLM 기반 보고서 생성 모듈은 독립적으로 동작하는 것을 확인하였다. 다만 현재 각 모듈은 개별적으로 구현된 상태이며, 예측 모델의 실제 출력값이 보고서 생성 모듈로 자동 전달되는 통합 파이프라인은 아직 완성되지 않았다. 향후 각 모듈 간 인터페이스를 정의하고 전체 시스템을 연동하여 완전한 end-to-end 파이프라인을 구축할 예정이다.

1. 준지도학습 기반 멀티모달 융합 모델을 활용한 난소암 악성도 및 재발 예측

본 연구에서는 설계 단계에서 정의한 멀티태스크·멀티모달 구조와 Mean Teacher 기반 준지도학습 프레임워크를 실제로 구현하고, 3종의 이미지 인코더 백본(ResNet50-Fusion, ViT-Fusion, Hybrid-Fusion)에 대한 비교 실험을 수행하였다. 구현 과정에서 데이터 누수 문제, 평가 지표 편향 문제 등이 발견되었으며 이를 단계적으로 수정하였다.

a. 멀티모달 융합 모델 구현

환자당 8장의 CT 슬라이스($224 \times 224 \times 3$)와 9개의 임상 피처를 입력으로 받는 MultiModalBinaryFusionModel을 구현하였다. 이미지 인코더는 ResNet50, ViT-B/16, CNN-Transformer Hybrid(ResNet50 + Transformer Encoder) 세 가지 백본을 비교 실험하였으며, 임상 데이터는 TabularMLPEncoder($256 \rightarrow 128 \rightarrow 16$)로 저차원 벡터로 압축된다. 재발 예측 헤드는 이미지 특징과 임상 특징을 결합하여 예측하고, 악성 예측 헤드는 이미지 특징만을 사용한다. 임상 피처에 대해 Tab Drop($p=0.9$)과 Tab Scale(0.1)을 적용하여 이미지 특징에 대한 과도한 의존을 방지하고 학습 안정성을 확보하였다.

b. Mean Teacher 기반 준지도학습 (semi-supervised learning) 구현

재발 라벨이 없는 Unlabeled 데이터를 활용하기 위해 Mean Teacher 방식을 적용하였다. Student 모델은 역전파로 학습하며, Teacher 모델은 Student 파라미터의 EMA(decay=0.999)로 갱신된다. Unlabeled 데이터에 대해 두 모델의 재발 예측 확률 간 MSE를 Consistency Loss로 정의하고, Consistency Ramp-up 스케줄러를 통해 학습 초기에는 가중치를 낮추다가 점차 증가시켜 학습 초반의 불안정한 Teacher 예측이 학습에 과도하게 반영되는 것을 방지하였다. 악성 여부 라벨은 Labeled·Unlabeled 데이터 모두에 존재하므로 두 데이터셋 모두에 Supervised Loss를 적용하였다. 총 손실 함수는 $L = L_{\text{rec}} + 0.3 \times L_{\text{mal}} + \lambda(t) \times L_{\text{cons}}$ 로 정의된다.

c. 데이터 누수 방지 및 평가 설계

5-Fold Cross-Validation에서 환자 단위로 fold를 분리하여 데이터 누수를 방지하였다. 악성 예측 평가 시, 재발 라벨과 악성 여부 라벨 간 강한 상관관계(재발=1 환자의 100%가 악성)로 인한 평가 편향을 방지하기 위해, Malignancy Validation Set을 recurrence=0/1/-1 전체 환자로 구성하는 별도의 평가 체계를 설계하였다. Best 모델 선택 기준은 val_rec_auc로 고정하였으며, Early Stopping(patience=10)을 적용하였다.

d. Grad-CAM 기반 예측 결과 시각화 구현


모델 예측 결과의 해석 가능성을 높이기 위해 Grad-CAM 기반 시각화 기능을 구현하였다. 환자당 8개의 CT 슬라이스 각각에 대해 독립적으로 Grad-CAM을 계산하며, 구체적인 구현 방식은 다음과 같다.

슬라이스별로 이미지 인코더의 마지막 합성곱 레이어(Layer4)에 forward hook을 등록하여 feature map을 추출하고, Layer4 파라미터에 대한 gradient를 계산한다. 추출된 gradient를 채널 방향으로 평균하여 각 채널의 가중치를 산출하고, 이를 feature map에 가중합산한 뒤 ReLU를 적용하여 양의 기여 영역만 추출한다. 생성된 CAM은 원본 CT 슬라이스 크기(224×224)로 bilinear interpolation을 통해 업샘플링되며, 0~1로 정규화된다. 최종적으로 정규화된 히트맵은 jet colormap을 적용하여 원본 CT 영상에 $\alpha=0.5$ 로 오버레이된다.

Transformer 기반 Hybrid 모델에서는 Grad-CAM과 함께 슬라이스별 Attention Weight도 함께 시각화하였다. CLS 토큰과 각 슬라이스 토큰 간의 cosine similarity를 계산하고 softmax를 적용하여 슬라이스별 attention score를 산출하며, 이를 CT 슬라이스 테두리 색상 및 굵기로 표현하여 모델이 상대적으로 중요하게 판단한 슬라이스를 직관적으로 확인할 수 있도록 하였다.

구현 과정에서 Backbone이 Freeze된 상태에서는 gradient가 계산되지 않는 문제가 발생하였다. 이를 해결하기 위해 Grad-CAM 계산 시에만 Layer4 파라미터를 일시적으로 requires_grad=True로 설정하고, 계산 완료 후 원래 상태로 복원하는 방식을 적용하였다.

생성된 슬라이스별 Grad-CAM 히트맵 이미지는 PNG 형식으로 저장되며, YOLO 기반 병변 탐지 결과와 함께 RAG 모듈로 전달되어 최종 임상 보고서에 시각적 근거로 첨부된다. 이를 통해 의료진과 환자는 모델의 예측 결과뿐만 아니라 예측의 판단 근거가 된 CT 영상 내 주요 영역을 보고서 내에서 직접 확인할 수 있다.



[그림 5] Grad-CAM 히트맵 시각화 결과

2. YOLO 기반 병변 위치 탐지 모듈

a. 라벨 변환 및 YOLO 학습 데이터 구성

학습 데이터 구성 시 가장 중요하게 고려한 사항은 데이터 누수 방지였다. 초기 구현에서는 slice 단위로 학습/검증 데이터를 분리하였으나, 동일 환자의 슬라이스가 학습과 검증 양쪽에 동시에 포함되는 문제가 발견되었다. 이를 해결하기 위해 class_name과 patient_id를 결합한 patient_key 단위로 환자를 관리하고, 클래스별로 각 15%의 환자를 검증 데이터로 분리하는 patient-level split을 구현하였다. 분리 결과는 manifest JSON 파일로 저장하여 재현성을 보장하였으며, train/val 환자 간 overlap이 없음을 코드 내에서 명시적으로 검증하였다.

b. YOLOv8 파인튜닝

사전학습된 YOLOv8s 가중치를 초기값으로 사용하여 난소암 CT 영상에 특화된 파인튜닝을 수행하였다. 난소암 병변은 단일 클래스(lesion)로 정의하여 single_cls=True로 설정하였다. 구현 과정에서 원본 데이터셋의 Training/Validation 폴더 구분을 YOLO 학습 split 기준으로 그대로 사용하지 않고, 전체 데이터를 합산한 뒤 patient-level로 새로 분리하는 방식을 채택하였다. 이는 원본 폴더 구분이 classifier 5-fold split과 무관하게 나뉘어 있어 YOLO 검증 데이터의 대표성을 보장하기 어렵기 때문이다. 학습 완료 후 best.pt 가중치를 저장하고, RETRAIN_YOLO 플래그를 통해 이미 학습된 가중치가 있으면 재학습 없이 재사용할 수 있도록 구현하였다.

c. 위치 메타데이터 생성 파이프라인

학습된 YOLO 모델을 활용하여 기존 classifier용 npz에 저장된 환자별 selected_slices 8장에 대해 위치 메타데이터를 생성하는 파이프라인을 구현하였다. 기존 classifier npz는 수정하지 않고 patient_ids 순서만 참조하여 동일한 순서로 위치 메타데이터를 생성하고 별도 파일로 저장하였다.

각 슬라이스에 대해 추출되는 정보는 다음과 같다.

- source_path: 원본 CT 이미지 경로
- yolo_bbox: YOLO 예측 bounding box 좌표 (x1, y1, x2, y2)
- yolo_confidence: 탐지 신뢰도
- yolo_found_flag: 병변 탐지 성공 여부
- polygon_bbox: 기존 annotation 기반 GT bbox (YOLO 결과 비교용)
- location_text: 위치 정보를 임상적으로 해석한 텍스트

location_text는 병변 중심 좌표를 영상 전체 크기 대비 상대적 위치로 계산하여 "영상 기준 좌측/중앙/우측", "상방/중간/하방" 형태로 변환하고, 병변 크기를 전체 영상 면적 대비 비율로 소형(2% 미만)/중형(2~10%)/대형(10% 이상)으로 분류하여 생성된다. 저장 형식은 npz와 JSONL 두 가지로 구성하여 후속 RAG 모듈에서 유연하게 활용할 수 있도록 하였다.

d. 추론 파이프라인 연동

추론 단계에서는 분류 모델과 YOLO 모듈이 동일한 원본 CT 영상을 입력으로 받아 독립적으로 동작한다. 분류 모델은 전처리된 3채널 이미지를 입력으로 악성/양성 예측 및 재발 예측 결과를 생성하고, YOLO 모듈은 원본 CT 영상에서 병변 위치 정보를 추출한다. 두 모델의 결과는 아래와 같은 구조화된 텍스트로 통합된다.

항목	내용
위치	영상 기준 좌측 중간 높이
크기	중형 (142x138px, 면적비 5.4%)
YOLO confidence	0.812
악성 예측 확률	0.91
재발 예측 확률	0.74

통합된 정보는 Qwen 2.5 기반 RAG 모듈의 프롬프트 컨텍스트로 전달되어 임상 보고서 생성에 활용된다. 이를 통해 단순 예측 수치뿐만 아니라 병변의 위치 및 크기 정보가 포함된 근거 기반 보고서 생성이 가능하다.

3. Retrieval-Augmented Generation (RAG) 기반 임상 보고서 생성

a. 프롬프트 설계

```
prompt = f"""
You are a careful medical AI report assistant for an ovarian cancer prediction
project.

The retrieved evidence is written in English.
Your final output must be written in Korean only.

Core safety rule:
Use only the retrieved evidence.
Do not use outside medical knowledge.
Do not invent diagnosis, subtype, treatment, medication, survival rate, recurrence
risk, prognosis, follow-up interval, or clinical recommendation.

Very important output rule:
Do not copy the retrieved evidence verbatim.
Do not print source file paths.
Do not list retrieved chunks.
Do not output English evidence text.
Do not translate the retrieved evidence line by line.
You must rewrite the evidence into Korean patient-friendly explanations.

Citation formatting rule:
Do not write citations as section headers like "***S1**:".
Do not write "[출처: S1]" on a separate line.
Each citation must appear only at the end of a Korean sentence.
Bad example:
[출처: S1]
English copied text...

Bad example:
***S1**: 수술 후 진단 및 검사 지침에 따르면...

Good example:
```


난소암의 최종 진단은 영상만으로 단정하기보다 병리학적 확인을 통해 이루어질 수 있습니다. [출처: S1]

If the retrieved evidence does not support a claim, write exactly:

"해당 근거는 검색된 DB에서 찾지 못했습니다."

Project limitation:

This AI system does not provide detailed subtype classification.

Do not mention detailed diagnosis, histologic subtype, or hierarchical diagnosis.

Only explain:

1. benign/malignant tendency,
2. recurrence-related tendency,
3. lesion side/location,
4. image-based attention finding,
5. evidence-based guideline or paper content retrieved from DB.

Medical wording rule:

Use cautious wording.

Use "의심됩니다", "가능성이 있습니다", "확인이 필요합니다", "고려될 수 있습니다".

Do not say "발견되었습니다" for AI image findings.

Do not say "확진입니다".

Do not say "반드시".

Do not say "완치".

Do not overgeneralize evidence about advanced-stage ovarian cancer to all ovarian cancer patients.

Do not use raw statistics such as "80%" unless the patient group and condition are clearly stated.

Translate "systemic therapy" as "전신 치료" or "전신 항암치료".

Translate "suspected peritoneal metastasis near right ovary" as "우측 난소 주변 복막 전이가 의심되는 소견".

[Patient Data]

- Lesion location: {lesion_location}
- Simplified lesion side: {lesion_side}
- AI malignancy prediction raw value: {malignancy_raw}
- AI malignancy explanation in Korean: {malignancy_kor}
- AI recurrence prediction raw value: {recurrence_raw}
- AI recurrence explanation in Korean: {recurrence_kor}
- Grad-CAM or image attention finding: {grad_cam_finding}
- Korean prediction summary: {prediction_summary}

[Available Sources]

{source_list}

[Retrieved Evidence]

{context}

[Required Korean Output Format]

환자용 AI 예측 설명 보고서

1. 이번 AI 예측 결과 요약

AI 예측값을 바탕으로 3문장 이내로 설명하세요.

세부 진단명이나 subtype은 쓰지 마세요.

확정 진단처럼 쓰지 마세요.

이 섹션은 환자 입력값과 AI 예측값 설명이므로 출처가 없어도 됩니다.

2. 병변 위치와 영상 참고 소견

병변 위치와 영상 참고 소견을 2~3문장으로 설명하세요.

영상 소견의 임상적 의미를 단정하지 마세요.

retrieved evidence에 근거가 있는 의학적 설명을 추가하는 경우 문장 끝에 출처를 붙이세요.

근거가 부족하면 "해당 근거는 검색된 DB에서 찾지 못했습니다."라고 쓰세요.

3. 검색된 논문/가이드라인에서 확인된 내용

검색된 근거를 그대로 복사하지 말고, 환자가 이해할 수 있는 한국어 문장으로 재작성하세요.

3~5개의 bullet point로 작성하세요.

각 bullet point는 반드시 [출처: S번호]로 끝나야 합니다.

출처는 문장 맨 앞에 쓰지 말고 문장 끝에만 쓰세요.

근거가 부족하면 "해당 근거는 검색된 DB에서 찾지 못했습니다."라고 쓰세요.

4. 의료진과 추가로 확인할 수 있는 부분

검색된 근거에 기반해 의료진과 확인할 수 있는 내용을 2~4개의 bullet point로 작성하세요.

각 bullet point는 반드시 [출처: S번호]로 끝나야 합니다.

출처는 문장 맨 앞에 쓰지 말고 문장 끝에만 쓰세요.

근거가 부족하면 "해당 근거는 검색된 DB에서 찾지 못했습니다."라고 쓰세요.

5. 꼭 기억할 점

AI 결과는 참고용이며 확정 진단이 아니라고 설명하세요.


최종 판단과 치료 결정은 의료진이 해야 한다고 설명하세요.

불안을 과도하게 유발하지 말고, 안전하고 신중한 표현을 사용하세요.
일반적인 안전 안내 문구는 출처 없이 작성해도 됩니다.

Write the final report in Korean only.

- 본 연구에서는 RAG 기반 임상 보고서 생성 과정에서 LLM의 환각을 최소화하기 위해 프롬프트 제약 조건을 명확히 설정하였다. 구체적으로, LLM이 임상 보고서를 생성할 때 FAISS 기반 벡터 DB에 저장된 난소암 관련 가이드라인 및 논문 자료만을 근거로 활용하도록 지시하였다. 또한 관련 근거가 검색된 경우에는 생성 문장 뒤에 해당 출처를 반드시 표기하도록 하여, 보고서 내 설명의 근거와 신뢰성을 확인할 수 있도록 하였다.
- 반면, 벡터 DB에서 환자 정보와 관련된 근거를 찾지 못한 경우에는 LLM이 임의로 의학적 판단이나 설명을 생성하지 않도록 “해당 근거는 검색된 DB에서 찾지 못했습니다.” 라는 문구를 출력하도록 설정하였다. 이를 통해 검색 기반 근거가 없는 내용이 보고서에 포함되는 것을 방지하고, 의료 정보 생성 과정에서 요구되는 정확성과 투명성을 확보하고자 하였다.

b. faissDB 구축



- 본 연구에서 구축한 가이드라인 및 논문 자료는 다음과 같다. 현재는 난소암 관련 임상 가이드라인과 연구 논문을 중심으로 FAISS 기반 벡터 DB를 구성하였으며, 향후 추가적인 공신력 있는 문헌과 가이드라인을 지속적으로 보완할 예정이다.
- 구체적으로, data 폴더 하위에 저장된 PDF 파일들은 텍스트 추출 과정을 거친 후 일정한 chunk 단위로 분할된다. 이후 각 chunk는 embedding 모델을 통해 벡터 형태로 변환되며, 변환된 벡터는 FAISS 인덱스에 저장된다. 이를 통해 문서 내용을 단순 키워드 기반이 아니라 의미적 유사도 기반으로 검색할 수 있도록 구성하였다.
- 임상 보고서 생성 단계에서는 환자의 병변 위치, 악성/양성 예측 결과, 재발 가능성, 영상 소견 등의 정보를 바탕으로 검색 query를 생성한다. 이후 생성된 query와 의미적으로 유사한 문서 chunk를 FAISS DB에서 검색하고, 검색된 근거 문서를 LLM 기반 임상 보고서 생성 과정에 활용한다. 이러한 구조를 통해 환자별 예측 결과와 관련성이 높은 임상 근거를 보고서에 반영할 수 있도록 하였다.

c. 사용 모델

- 본 연구에서는 LLM 기반 임상 보고서 생성 성능을 비교하기 위해 Llama 2, Llama 3, Qwen2.5-1.5B-Instruct, Qwen 3.5-0.8B, Qwen 3.5-4B의 총 5가지 모델을 대상으로 비교 실험을 수행할 예정이다. 각 모델이 생성한 임상 보고서의 문장 자연스러움, 의학적 표현의 적절성, 검색 근거 반영 여부, 출처 표기 정확성 등을 비교하여 본 연구에 가장 적합한 로컬 LLM 모델을 선정하고자 한다.
- 현재 제시된 임상 보고서 결과는 로컬 환경에서 Qwen 3.5-0.8B 모델을 이용하여 생성한 예비 결과이다. 향후 안심존 서버 환경에서는 GPU를 활용하여, 상대적으로 더 높은 성능이 기대되는 Qwen 3.5-4B 모델을 기반으로 임상 보고서를 생성할 예정이다.
- 또한 보고서의 신뢰성을 높이기 위해, 보고서 생성 모델과 검증 모델을 분리하는 구조를 설계하고자 한다. 구체적으로, Qwen 3.5-4B 모델이 환자 정보와 FAISS DB에서 검색된 근거 문서를 바탕으로 임상 보고서를 생성하고, 이후 Qwen 3.5-0.8B 모델이 생성된 보고서에 포함된 출처가 실제 검색 결과 및 DB 내 문서와 일치하는지 검증하는 방식이다. 이를 통해 LLM이 근거 없는 내용을 생성하거나 존재하지 않는 출처를 제시하는 문제를 줄이고, RAG 기반 임상 보고서의 근거 신뢰성과 투명성을 강화하고자 한다.

IV. 참고 문헌

1. Bray, F., Ferlay, J., Soerjomataram, I., Siegel, R. L., Torre, L. A., & Jemal, A. (2018). Global cancer statistics 2018: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: A Cancer Journal for Clinicians*, 68(6), 394–424.
<https://doi.org/10.3322/caac.21492>
2. du Bois, A., Reuss, A., Pujade-Lauraine, E., Harter, P., Ray-Coquard, I., & Pfisterer, J. (2009). Role of surgical outcome as prognostic factor in advanced epithelial ovarian cancer: A combined exploratory analysis of three prospectively randomized phase 3 multicenter trials. *Cancer*, 115(6), 1234–1244. <https://doi.org/10.1002/cncr.24149>
3. Timmerman, D., Valentin, L., Bourne, T. H., Collins, W. P., Verrelst, H., & Vergote, I. (2016). Terms, definitions and measurements to describe the sonographic features of adnexal tumors: A consensus opinion from the International Ovarian Tumor Analysis (IOTA) group. *Ultrasound in Obstetrics & Gynecology*, 16(5), 500–505.
4. Christiansen, F., Konuk, E., Ganeshan, A. R., Welch, R., Palés Huix, J., Czekierdowski, A., Leone, F. P. G., Haak, L. A., Fruscio, R., Gaurilcikas, A., Franchi, D., Fischerova, D., Mor, E., Savelli, L., Pascual, M. À., Kudla, M. J., Guerriero, S., Buonomo, F., Liuba, K., Montik, N., Alcázar, J. L., Domali, E., Pangilinan, N. C. P., Carella, C., ... Epstein, E. (2025). International multicenter validation of AI-driven ultrasound detection of ovarian cancer. *Nature Medicine*, 31, 189–196.
<https://doi.org/10.1038/s41591-024-03352-3>
5. Tanno, R., Barrett, D. G. T., SELLERGREN, A., Ghaisas, S., Dathathri, S., See, A., Welbl, J., Lau, C., Tu, T., Azizi, S., Singhal, K., Schaekermann, M., May, R., Lee, R., Man, S., Mahdavi, S., Ahmed, Z., Matias, Y., Barral, J., ... Ktena, I. (2025). Collaboration between clinicians and vision–language models in radiology report generation. *Nature Medicine*, 31, 599–608.
<https://doi.org/10.1038/s41591-024-03302-1>
6. Zambrano Chaves, J. M., Huang, S.-C., Xu, Y., Xu, H., Usuyama, N., Zhang, S., Wang, F., Xie, Y., Khademi, M., Yang, Z., Awadalla, H., Gong, J., Hu, H., Yang, J., Li, C., Gao, J., Gu, Y., Wong, C., Wei, M., ... Poon, H. (2025). A clinically accessible small multimodal radiology model and evaluation metric for chest X-ray findings. *Nature Communications*, 16, 3108.
<https://doi.org/10.1038/s41467-025-58344-x>
7. Cai, H., Wang, C., Zhang, Y., Ding, H., Hong, W., Zhao, Y., Cheng, S., & Wang, Y. (2026). Decoding AI competence: Benchmarking large language models (LLMs) in ovarian cancer diagnosis and treatment—A systematic evaluation of generative AI accuracy and completeness. *Diagnostics*, 16(4), 616.
<https://doi.org/10.3390/diagnostics16040616>